Entrega 2 — Anticipar qué reclamos urbanos se resuelven en una semana

Machine Learning

Contexto

Esta entrega trabaja sobre datos abiertos reales del Uruguay.

La Intendencia de Montevideo publica, bajo la Licencia de Datos Abiertos del Uruguay, el registro de los reclamos que recibe a través de su Sistema Único de Reclamos: alumbrado público, limpieza y contenedores, saneamiento, arbolado, calles y veredas, entre otros. El archivo tiene más de 1,7 millones de filas, una por reclamo, con ingresos desde 2010.

Recurso	Dónde
Conjunto «Reclamos registrados en el Sistema Único de Reclamos de la Intendencia de Montevideo»	catalogodatos.gub.uy
Catálogo Nacional de Datos Abiertos	catalogodatos.gub.uy
Licencia de Datos Abiertos del Uruguay	gub.uy

La decisión

Cuando un vecino ingresa un reclamo, el área de la Intendencia que lo gestiona lo incorpora a su programación de trabajo. La Intendencia quiere dos cosas del registro histórico.

1. Anticipar, en el momento del ingreso, si el reclamo se va a resolver en una semana. Con esa estimación el sistema puede informar al vecino un plazo esperable, y el área puede derivar a seguimiento los reclamos que probablemente no se resuelvan a tiempo. Es una respuesta binaria: el reclamo se resuelve en 7 días corridos o menos desde su ingreso, o no. Esa columna no viene en el archivo: se construye, y construirla obliga a decidir antes qué hacer con los registros para los que no tiene sentido.
2. Encontrar focos: zonas de la ciudad donde un mismo problema se concentra lo suficiente como para justificar una intervención de conjunto, en lugar de una respuesta reclamo por reclamo. Esta pregunta no tiene respuesta correcta en el archivo; la responde un agrupamiento, y su valor depende de que se lo pueda interpretar.

Cómo se registra un reclamo

Cada reclamo se registra al ingresar con su fecha, el tipo de problema —dentro de una jerarquía de área, grupo y tipo— y la ubicación del punto reclamado. A partir de ahí el área lo gestiona, y el registro no guarda la historia del reclamo sino su estado actual: en qué estado se encuentra y desde qué fecha está en ese estado. El archivo es, por eso, una foto del sistema en el momento en que se publicó.

El modelo se ejecuta en el momento en que el reclamo ingresa. Toda información que use como entrada tiene que existir en ese instante. Determinar qué parte del registro cumple esa condición es parte del trabajo.

Los datos

Paso 1 — descargar el archivo

Desde el catálogo, el recurso «Reclamos»: un ZIP de unos 44 MB que descomprime a un CSV de unos 305 MB. Declarar en el notebook la fecha de descarga: el archivo se republica periódicamente, y dos descargas distintas pueden diferir en algún reclamo.

Paso 2 — la ventana de trabajo

Se trabaja con los reclamos ingresados entre el 1.º de enero de 2017 y el 31 de diciembre de 2019. Esa ventana deja afuera los años en que el registro todavía tiene muchos reclamos sin cerrar, y los años en que la operación cambió por la pandemia.

Paso 3 — el año de prueba

Los reclamos ingresados en 2019 son el conjunto de prueba, y se apartan antes de cualquier ajuste. Solo se usan en las secciones 7 y 8, que vienen después de elegir los modelos. Toda elección —preparación, hiperparámetros, familia de modelos— se hace con los reclamos de 2017 y 2018. Es la forma en que el modelo se usaría: entrenado con el pasado, aplicado a reclamos que todavía no ocurrieron.

> Sobre la naturaleza de los datos. El archivo es el registro público tal como la Intendencia lo publica. Ninguna conclusión de este trabajo constituye un diagnóstico sobre la gestión de la Intendencia, y así debe declararse en la sección de conclusiones.

No se entrega diccionario de variables ni descripción de la calidad del archivo. El catálogo publica una descripción de campos, y consultarla es parte del trabajo profesional. Lo que ninguna descripción dice es en qué estado llega el archivo ni qué información existe en el momento en que el reclamo ingresa: caracterizar el conjunto es la primera consigna.

Qué hay que entregar

Un notebook construido sobre el template obligatorio `entrega_reclamos_im_template.ipynb`, que fija las ocho secciones y su orden. Cada sección tiene una consigna propia, y las secciones posteriores se apoyan en las decisiones de las anteriores.

1. Datos, respuesta y población

Documentar la ingesta —cuántas filas trae el archivo, cuántas caen en la ventana de trabajo y cuántas en cada año— y caracterizar el conjunto antes de ajustar ningún modelo: tipos, distribución de cada variable, filas repetidas, valores imposibles, cardinalidad de las variables categóricas y cómo se distribuyen los estados del reclamo según el año de ingreso. Contrastar el archivo con la descripción de campos publicada.

Construir después la respuesta a partir de la definición de la sección *La decisión*, y declarar la población sobre la que se modela: qué reclamos se excluyen, cuántos son y qué sesgo introduce cada exclusión en lo que el modelo aprende. Declarar también qué columnas quedan fuera de la matriz de entrada y por qué, una por una, distinguiendo la justificación de disponibilidad en el momento del ingreso de la justificación por desempeño.

Por último, apartar 2019 y elegir el esquema de validación con el que se van a tomar todas las decisiones sobre 2017–2018. La elección se justifica por cómo se va a usar el modelo.

La sección cierra con un informe de hallazgos: una tabla de tres columnas —defecto, evidencia que lo produce, decisión tomada—. Un hallazgo sin la cifra o el gráfico que lo produce no cuenta como hallazgo.

> Esta sección se apoya en validación temporal, que se dicta más adelante en el curso. El plazo de entrega lo contempla, pero conviene planificar el trabajo del grupo sabiéndolo.

2. Línea base

Antes de ajustar el primer modelo, reportar la línea base trivial —predecir para todos la prevalencia— y una regresión logística sobre el tipo de problema y la fecha de ingreso, sin la ubicación.

Las métricas son el ROC-AUC (de acá en más, AUC) y la average precision (AP), que resume la curva precision-recall. Leer la AP de la línea base trivial y decir por qué no es cero. Todo número posterior se informa contra esta línea base.

3. Coordenadas: qué necesita cada familia

> **Guía.** Las coordenadas del archivo son latitud y longitud en grados. A la latitud de Montevideo un grado de longitud mide unos 91 km y uno de latitud unos 111 km, así que una diferencia en grados no es una distancia física.
>
> - Para los métodos que usan distancias —k vecinos, máquinas de vectores de soporte con núcleo RBF, k-medias, DBSCAN— conviene proyectar a metros. Alcanza la aproximación local
>
> $$x = R\,(\lambda - \lambda_0)\cos\varphi_0, \qquad y = R\,(\varphi - \varphi_0),$$
>
> con λ la longitud y φ la latitud en radianes, (λ_0, φ_0) un punto de referencia en la ciudad y $R \approx 6\,371\,000$ m; o la proyección UTM 21S (EPSG:32721) con la biblioteca `pyproj`. En metros, además, los parámetros de un agrupamiento por densidad se leen como radios en la ciudad.
> - Las dos coordenadas se escalan con el mismo factor. Estandarizarlas por separado estira un eje respecto del otro y deforma la métrica.
> - Los árboles y sus ensambles no lo necesitan. Parten por umbrales sobre un eje a la vez, y un cambio de escala de ese eje mueve el umbral sin cambiar la partición.
> - La escala de las coordenadas frente al resto de las entradas importa para todo método que combine variables en una distancia o en un producto escalar: una columna en metros convive con columnas indicadoras que valen 0 o 1.

Corroborar la guía experimentalmente con k vecinos y un árbol de decisión, sobre el mismo esquema de validación, comparando dos pares de variantes. En cada par cambia una sola cosa:

1. La unidad. Coordenadas en grados contra coordenadas en metros.
2. La escala de las coordenadas frente a las demás entradas. Coordenadas en metros estandarizadas, de modo que queden en una escala comparable con el resto, contra coordenadas en metros sin escalar, con valores de miles al lado de columnas indicadoras de 0 y 1.

Reportar todo en una sola tabla y concluir qué de la guía se confirma en este problema, qué no cambia nada y por qué. Si un cambio no mueve la métrica, decirlo y explicarlo es una respuesta correcta.

4. Focos espaciales

Elegir un tipo de problema con al menos 2000 reclamos en 2017–2018, justificar la elección y agrupar sus ubicaciones —solo las de 2017–2018— con tres métodos:

- k-medias, con K elegido a partir de la curva del silhouette score en función de K. La forma de esa curva se interpreta: qué dice sobre la existencia de un número natural de zonas;
- jerárquico aglomerativo, con enlace de Ward y con enlace simple;
- DBSCAN, con ε y el mínimo de vecinos elegidos a partir de un gráfico de k-distancias construido antes de agrupar.

Reportar en una tabla, para cada método, el número de grupos, cuántos reclamos quedan sin grupo y el silhouette score. Para DBSCAN, declarar cómo se trató el ruido al calcular el silhouette score y por qué.

Mostrar cada resultado sobre un mapa —un gráfico de dispersión de las coordenadas alcanza— e interpretarlo en el lenguaje del caso. ¿Qué método encuentra focos y cuál reparte la ciudad en zonas? ¿Elige el silhouette score el método que mejor responde a la pregunta de la Intendencia? Recomendar un conjunto concreto de focos, con su ubicación aproximada, su tamaño y el criterio que lo sostiene.

5. El agrupamiento como atributo

Usar un agrupamiento de las ubicaciones como entrada de la regresión logística: zonas de k-medias ajustadas sobre las coordenadas, representadas por la etiqueta de la zona o por las distancias a los centroides. Comparar, sobre el mismo esquema de validación, la logística con las coordenadas crudas contra la logística con las zonas, y explicar con qué criterio se eligió K.

El agrupamiento es una transformación que aprende de los datos, y como toda transformación de ese tipo va dentro del `Pipeline`. Explicar qué cambia si se lo ajusta afuera, y qué pasaría con cualquier representación de la zona que use la respuesta.

Concluir qué le aporta la representación a un modelo lineal, y por qué.

6. Seis familias con ajuste de hiperparámetros

Ajustar sobre la misma preparación k vecinos más cercanos, un árbol de decisión, una máquina de vectores de soporte con núcleo RBF, un bosque aleatorio, un modelo de boosting y una red neuronal, cada uno con sus hiperparámetros elegidos con el esquema de validación de la sección 1.

- Se trabaja con una submuestra de 50 000 reclamos de 2017–2018, estratificada por año y la misma para todas las familias. La máquina de vectores de soporte usa 10 000 de esos 50 000.
- Las grillas se declaran. Alcanzan dos a cuatro valores por hiperparámetro, sobre los hiperparámetros que más pesan en cada familia. Si el valor elegido queda en un borde de la grilla, se dice.
- Se registra el tiempo de ajuste y de predicción de cada familia.

Reportar una tabla con la configuración elegida, el desempeño en validación y el costo de cómputo de cada familia. No se toca 2019.

7. Validación y comparación final sobre 2019

Entrenar cada familia, con la configuración elegida en la sección 6, sobre la submuestra de 2017–2018, y evaluarla una sola vez sobre 2019. Reportar en una tabla AUC, AP y los tiempos de ajuste y predicción.

Para el bosque aleatorio, agregar a la comparación dos estimaciones más del mismo desempeño: la del esquema de validación de la sección 1 y la de una validación cruzada de k folds con las filas mezcladas al azar, sobre los mismos datos de 2017–2018. Reportar la brecha entre las estimaciones y el resultado sobre 2019 como número, e identificar el mecanismo que la produce: qué tienen en común un reclamo de validación y los de entrenamiento en cada esquema.

Elegir un modelo para recomendar, pesando desempeño, costo de cómputo y lo que el modelo permite explicar. Una diferencia de pocas milésimas no elige un modelo.

Esta sección se apoya en validación temporal, que se dicta más adelante en el curso.

8. Importancias y conclusiones

Para el mejor modelo basado en árboles de la sección 6, calcular la importancia por impureza y la importancia por permutación, esta última sobre 2019. Reportar las dos en una sola tabla, explicar por qué no coinciden y decir cuál de las dos habla del problema y cuál habla del ajuste.

Cerrar con las conclusiones: qué se recomienda a la Intendencia —el modelo de la sección 7 y los focos de la sección 4—, con qué desempeño contra la línea base, qué determina según el modelo que un reclamo se resuelva en una semana y cuánto pesa la ubicación. Y qué no se puede concluir con estos datos: los límites tienen que ser los de este caso, no una lista genérica de advertencias sobre el aprendizaje automático.

Qué hace suficiente a una justificación

Buena parte de las decisiones de esta entrega son abiertas: qué reclamos excluir, cómo codificar el tipo de problema, qué esquema de validación usar, qué modelo recomendar. Se evalúa la justificación, no la coincidencia con una respuesta esperada. Una justificación es suficiente cuando cumple las tres condiciones:

1. Nombra la alternativa que se descartó.
2. Dice qué propiedad de los datos o del problema descarta esa alternativa. La propiedad medida, no la costumbre: «es buena práctica» no es una propiedad.
3. Cuando la decisión es medible, muestra la medición.

Una justificación que solo describe lo que se hizo no es una justificación. Y en las secciones 3, 5 y 7, que comparan flujos, la comparación solo vale si difieren en una sola cosa.

Alcance

Lo que sigue no se pide y no se evalúa. Está acotado para que el esfuerzo del grupo se concentre en las ocho secciones:

- Reducción de dimensión y mezclas de gaussianas.
- Elección de un umbral por costos. La respuesta de esta entrega es una probabilidad.
- Validación cruzada anidada, pruebas estadísticas formales de comparación de modelos y métodos de explicación posteriores al ajuste más allá de las dos importancias de la sección 8.
- Búsquedas de hiperparámetros extensas. Las grillas de la sección 6 son deliberadamente chicas.
- Análisis de supervivencia. El estado de los reclamos se mide y se declara; no se modela.
- Cruces con otras fuentes de datos, como el censo, el clima o el padrón. El caso se resuelve con lo que el archivo trae.
- Bibliotecas geoespaciales. Un gráfico de dispersión de las coordenadas es un mapa suficiente.

No hay un desempeño mínimo que alcanzar. Una conclusión honesta y bien sostenida de que una familia no aporta, o de que dos modelos son indistinguibles, vale más que una cifra alta sin respaldo.

Condiciones de entrega

Modalidad	Grupos de 4 integrantes
Peso	10 % de la calificación final
Formato	Notebook construido sobre `entrega_reclamos_im_template.ipynb`, respetando las ocho secciones y su orden
Estado	Ejecutado de punta a punta, con todas las salidas visibles
Vencimiento	Jueves 5 de noviembre

Un notebook sin ejecutar no está entregado. Las celdas de código tienen que mostrar su salida, y las afirmaciones del texto tienen que corresponderse con esa salida: una conclusión que el notebook no respalda con un número visible se corrige como si no estuviera.

El notebook tiene que poder reproducirse. El código de ingesta queda en el notebook, y la ruta del archivo descargado y su fecha de descarga se declaran en una única celda al principio. Toda celda con aleatoriedad fija su semilla.

Se corrige contra este enunciado, no contra el template. Un grupo que se aparte de la estructura del template pero responda todo lo que este documento pide no se penaliza por apartarse.

Está permitido el uso de herramientas de IA para asistir la escritura, el análisis y la programación, con una sola condición: la comprensión es propia e intransferible. Se podrá pedir a cualquier integrante que explique oralmente cualquier fragmento de código, resultado o análisis entregado.