Guía para defender la Entrega 2

Resume qué hicimos en cada sección, por qué, y con qué números lo sostenemos. Todas las cifras salen de las salidas de entrega_reclamos_im.ipynb. En la defensa le pueden pedir a cualquiera de los cuatro que explique cualquier celda: esta guía ayuda, pero no reemplaza leer el código.

Las cifras de validación son de entrenar con 2017 y validar con 2018 sobre la muestra de 50 000. Las de «2019» son la prueba, usada una sola vez.

Presentación de un minuto

Usamos el registro abierto de reclamos de la Intendencia, de 2017 a 2019. Antes de modelar encontramos tres cosas que condicionan todo: el catálogo de Limpieza cambió el 26/12/2017, la proporción de reclamos cerrados en una semana sube de 33 % a 43 % en dos años, y el 12 % de los reclamos se cierra administrativamente más de un año después. Por eso validamos en el tiempo: entrenamos con 2017, validamos con 2018 y probamos una sola vez con 2019. Lo que más determina que un reclamo se cierre en una semana es el tipo de problema; la ubicación suma algo. En 2019, el mejor modelo es una regresión logística con distancias a 40 zonas de k-medias: AP 0,720 contra 0,700 sin ubicación, más barata y más explicable que el boosting o la red. Los modelos de árboles eran los mejores en validación pero no en 2019. Para los focos usamos bocas de tormenta obstruidas: DBSCAN encuentra 52 focos y recomendamos los 5 mayores. Nada de esto es un diagnóstico de la gestión de la Intendencia.

Cómo está armado el código

- **proyectar(longitud, latitud)**: la fórmula de la consigna para pasar de grados a metros respecto de un punto fijo (34,87 °S, 56,17 °O).
- **flujo(modelo, geo, k_zonas)**: el Pipeline del lab 4. Hace one-hot de área, grupo, tipo, mes y día de la semana; agrega las coordenadas (geo) o, si se pide, las distancias a k_zonas centroides de k-medias.
- **evaluar(modelo, entrenamiento, evaluacion, columnas)**: ajusta, puntúa y devuelve AUC, AP y los dos tiempos. Si el modelo no da probabilidades (la SVM), usa decision_function.
- **crear(familia, p)**: devuelve el estimador de cada familia con los hiperparámetros p. La sección 6 recorre cada grilla con ParameterGrid, como el lab 14.
- **ent, val**: la muestra de 2017 y la de 2018. **muestra**: los 50 000. **prueba**: los 133 211 reclamos de 2019.

1. Datos, respuesta y población

- **Ingesta:** 1 709 419 reclamos en el archivo; 395 643 en la ventana (130 178, 125 227 y 140 238 por año).
- **Respuesta:** resuelto_7d = 1 si entre el ingreso y la fecha del estado Finalizado hay 7 días o menos. Las fechas no tienen hora, así que se cuentan días.
- **Población:** quitamos 14 copias, 17 492 anulados o abiertos y 1 reclamo con cierre antes del ingreso. Quedan 378 136. Sacar los abiertos sube un poco la prevalencia, y más en 2019 (0,9 % en proceso) que en 2017 (0,2 %).
- **Defectos clave:**

    - El cambio de catálogo: «Muebles y electrodomésticos» pasa del código 301 al 1402, «Podas» del 241 al 1381, etc. El 43,8 % de la validación 2018 tiene tipos con menos de 100 casos en 2017.
    - La prevalencia cambia: 33,2 %, 40,6 % y 42,9 %.
    - Los cierres tardíos: la mediana de la demora es 13 días, el percentil 90 es 533; el 23/6/2021 se cerraron 1 565 reclamos de la ventana el mismo día.
    - La descripción de campos dice UTM y el archivo trae grados.
- **Entradas:** área, grupo y tipo (códigos), mes y día de la semana, y ubicación. Afuera: estado y fecha del estado (no existen al ingresar), nombres (redundantes) y el número de reclamo.
- **Validación:** 2017 → 2018. Reproduce el uso: entrenar con el pasado y aplicar al año siguiente. La validación mezclada pone reclamos del mismo día de los dos lados (sección 7).

2. Línea base

- Prevalencia: AUC 0,500, AP 0,406. **La AP de un puntaje constante es la prevalencia del conjunto evaluado**, no cero: cualquier corte toma una porción al azar y su precisión es la proporción de positivos.
- Logística sin ubicación: AUC 0,718, AP 0,635.
- La fecha como tendencia (años desde 2017) no aporta (AP 0,634) y siempre cae fuera del rango de entrenamiento: por eso entra como mes y día de la semana.

3. Coordenadas

Variante	k vecinos (AUC / AP)	Árbol
Grados	0,721 / 0,641	0,642 / 0,567
Metros sin escalar	0,563 / 0,447	igual
Metros estandarizados	0,728 / 0,645	igual

- **El árbol no cambia:** corta un eje por vez y el orden de los valores no cambia.
- **En k vecinos manda la escala frente a las indicadoras.** En metros (desvío 4 600) la distancia física tapa al tipo de problema y la AP cae casi a la prevalencia. En grados (desvío 0,05) la ubicación casi no cuenta.
- La estandarización divide x e y por el **mismo** factor fijo (5 km): así no se deforma la ciudad y no se aprende nada de los datos.

4. Focos

- **Tipo:** boca de tormenta obstruida (2 984 reclamos en 1 976 puntos). Bache no servía: DBSCAN unía 3 677 baches en un grupo de 9 km.
- **k-medias:** curva irregular de 0,347 a 0,454 (máximo en K = 8). No hay un número natural de zonas.
- **ε:** la mediana de la distancia al 10.º vecino, 270 m. El codo de la curva (600-700 m) une todo el casco urbano: separa ciudad de periferia, no focos de fondo.
- **Resultados:** k-medias y Ward reparten la ciudad en 8 zonas; enlace simple encadena (un grupo de 2 968); DBSCAN encuentra 52 focos y deja 1 065 reclamos como ruido.

- **Silhouette:** elige k-medias (0,454 contra 0,407 de DBSCAN sin ruido), que no encuentra focos. Premia la compacidad, no la concentración.
- **Focos recomendados:** los 5 grupos de DBSCAN con 70 reclamos o más: 770 reclamos en total, radios de 0,6 a 1,1 km. El quinto tiene 74 reclamos en solo 29 puntos: son pocas bocas reclamadas muchas veces.

5. Zonas como atributo

- Distancias a los centroides de k-medias, **dentro** del ColumnTransformer.
- Grilla K □ {5, 10, 20, 40, 80, 160}. La AP sube cada vez menos; criterio: el menor K a menos de 0,005 de la mejor AP, que es **K = 40** (AP 0,667 contra 0,653 de las coordenadas crudas).
- **Por qué ayuda a un modelo lineal:** con x e y, la logística solo puede representar un efecto en línea recta hacia algún lado. Con 40 distancias puede dar un efecto distinto a cada parte de la ciudad.
- **Afuera del pipeline,** los centroides se calcularían con las ubicaciones de validación. **Con la respuesta** (tasa de cierre por zona), cada reclamo ayudaría a definir su propia entrada.

6. Seis familias

Familia	Elegida	AP validación
k vecinos	k = 51	0,641
Árbol	sin límite de profundidad, hoja 120	0,657
SVM RBF (10 000)	C = 0,5, γ = 0,1	0,614
Bosque	70 % de variables, hoja 5	0,707
Boosting (AdaBoost)	profundidad 8, 600 etapas	0,715
Red neuronal	una capa de 32, α = 0,01	0,698

Bordes declarados: la profundidad del árbol (sin límite es el extremo natural), el 70 % del bosque (meseta: 0,705 con 40 %) y la profundidad 8 del boosting (la AP sigue subiendo).

7. 2019

Modelo	AUC	AP
Logística sin ubicación	0,741	0,700
Logística con 40 zonas	0,767	**0,720**
Boosting	**0,767**	0,683
Red neuronal	0,749	0,711
Bosque	0,753	0,651

- **Bosque, tres estimaciones:** validación 2017 → 2018 AUC 0,761, mezclada 0,882 y 2019 0,753. La mezclada sobrestima en 0,13.

- **Mecanismo de la brecha:** el 85 % de los reclamos de validación mezclada tiene en entrenamiento otro del mismo tipo y del mismo día, y la etiqueta de esos pares acierta el 69 % (contra 63 %). Al usarse, eso no existe.
- **Recomendado:** logística con 40 zonas. Tiene la mejor AP, empata el AUC del boosting, ajusta en unos segundos (el boosting tarda casi un minuto) y se explica con coeficientes. La red queda a 0,009 de AP: no alcanza para elegirla.

8. Importancias

- **Modelo:** el boosting, el mejor basado en árboles por AP de validación.
- **Lectura:** la impureza infla las variables con muchos cortes (coordenada y 0,216, mes 0,132), que en 2019 casi no aportan (permutación 0,013 y 0,007). **La impureza habla del ajuste; la permutación sobre 2019, del problema.**
- **El tipo de problema domina** (permutación 0,151):
  - Se cierran en una semana casi siempre: conexión obstruida (94 %) y animales muertos (95 %).
  - Casi nunca: reposición de vereda (0,4 %) y traslado de contenedor (1,5 %).
- **Ubicación:** sin ella, el boosting pierde 0,048 de AUC; en la logística, las zonas suman 0,020 de AP.

Los dos puntos débiles y cómo defenderlos

Son las dos cosas que un docente estricto nos puede marcar. Las dos tienen defensa, pero hay que conocer los números y no negar lo que es cierto.

Tabla de apoyo (validación = entrenar con 2017 y evaluar en 2018; 2019 = entrenar con 2017-2018 y evaluar en 2019):

Modelo	AUC validación	AUC 2019	AP validación	AP 2019	AP sobre la prevalencia, validación	AP sobre la prevalencia, 2019
Logística sin ubicación	0,718	0,741	0,635	0,700	+0,229	+0,271
Logística con 40 zonas	0,749	0,767	0,667	0,720	+0,261	+0,291
Bosque	0,761	0,753	0,707	0,651	+0,301	+0,222
Boosting	0,785	0,767	0,715	0,683	+0,309	+0,254
Red neuronal	0,762	0,749	0,698	0,711	+0,292	+0,282

La prevalencia es 0,406 en 2018 y 0,429 en 2019. Por eso las AP de los dos años no se comparan directo: hay que mirar cuánto suben sobre la prevalencia (las dos últimas columnas).

Punto 1: «El modelo recomendado lo eligieron mirando 2019»

La crítica. El paso 3 de la consigna dice que toda elección, incluida la familia, se hace con 2017-2018. En validación el boosting le ganaba a la logística con zonas por 0,048 de AP, que no son milésimas. La logística sale recomendada por su resultado en 2019.

Cómo lo defendemos, en este orden:

1. **Todo lo que configura un modelo se eligió con 2017-2018.** La preparación, el K = 40 de las zonas (sección 5) y los hiperparámetros de las seis familias (sección 6) salieron de la validación. 2019 no cambió ningún hiperparámetro ni ninguna columna: cada modelo se evaluó una sola vez, tal como estaba. Eso es lo que protege el paso 3.
2. **La sección 7 pide elegir después de evaluar en 2019.** Su consigna dice «evaluarla una sola vez sobre 2019» y después «elegir un modelo para recomendar, pesando desempeño, costo de cómputo y lo que el modelo permite explicar». La recomendación es la respuesta a esa pregunta, no un ajuste del modelo.
3. **Dos de los tres criterios no dependen de 2019.** Que la logística es mucho más barata de ajustar (en validación el boosting ya tardaba unos 20 s en ajustar; en la sección 7, 2,7 s contra 49 s) y que se explica con sus coeficientes, mientras que el boosting no, se sabía antes de mirar 2019. Lo único que aportó 2019 es el desempeño, y ahí la logística no es peor: empata el AUC (0,767 los dos) y tiene más AP.
4. **Lo que mostró 2019 es que la validación sobrestimaba a los árboles, y eso es un resultado.** Las dos logísticas suben de validación a 2019; el bosque y el boosting bajan en AUC y en AP sobre la prevalencia (el boosting pasa de +0,309 a +0,254), y la red baja un poco. Las importancias de la sección 8 dicen por qué: la impureza les da mucho peso a la coordenada y y al mes, que en 2019 casi no aportan. Recomendar el boosting sabiendo eso sería ignorar la evidencia.

Lo que hay que reconocer si insisten: que la AP de 0,720 de la logística es un poco optimista, porque es la mejor de ocho modelos comparados sobre el mismo 2019. Por eso el texto no dice que sea «la mejor», sino que no es peor, cuesta mucho menos y se puede explicar. Y si solo pudiéramos usar la validación, habríamos elegido el boosting: su AP de 2019 (0,683, por debajo de la logística sin ubicación) muestra que esa elección habría sido peor.

Frase corta para la defensa: «Con 2019 no ajustamos nada: lo usamos una sola vez para la comparación que pide la sección 7. Costo y explicabilidad ya favorecían a la logística antes de mirar 2019, y 2019 mostró que la ventaja del boosting en validación no se sostenía.»

Punto 2: «En la sección 1 dicen que la validación es más exigente que el uso real, pero en la 7 es optimista»

La crítica. La sección 1 dice que, por el cambio de catálogo, 2017 → 2018 es más exigente que el uso real. En la sección 7, para el bosque, esa validación resultó optimista: AP 0,707 en validación contra 0,651 en 2019.

Cómo lo defendemos: las dos cosas pasan a la vez, porque hay dos efectos opuestos, y la tabla de arriba los separa.

1. **El efecto del catálogo hace la validación más exigente, y se ve en los modelos simples.** La validación entrena solo con 2017, cuando el catálogo nuevo casi no existía: el 43,8 % de la validación tiene tipos con menos de 100 casos. Para 2019 se entrena con 2017-2018, que ya incluye el catálogo nuevo, y esa proporción baja a 8,1 %. Por eso las dos logísticas, que dependen sobre todo del tipo de problema, mejoran de validación a 2019: el AUC sube de 0,718 a 0,741 y de 0,749 a 0,767, y la AP sobre la prevalencia también sube.
2. **El efecto del sobreajuste hace la validación optimista, y se ve en los árboles (y un poco en la red).** El bosque (sin límite real de profundidad, 70 % de las variables por corte) y el boosting (árboles de profundidad 8) aprenden combinaciones de lugar, tipo y mes propias de 2017-2018. En 2019 esas combinaciones valen menos, y eso pesa más que la ventaja del catálogo: bajan en AUC y en AP. La sección 8 lo respalda: la coordenada y y el mes tienen mucha importancia por impureza (0,216 y

0,132) y casi nada por permutación sobre 2019 (0,013 y 0,007).

Lo que hay que reconocer: la frase de la sección 1 era cierta para los modelos que dependen del tipo, pero quedó dicha en general, y para los árboles no se cumplió. La forma correcta de decirlo es: «La validación es más exigente en cobertura del catálogo, pero no protege contra el sobreajuste de los modelos complejos».

Frase corta para la defensa: «Son dos efectos opuestos. El catálogo hace la validación más dura para todos, y por eso la logística mejora en 2019. Los árboles además se sobreajustan a 2017-2018, y en ellos ese efecto gana. La tabla de validación contra 2019 muestra los dos.»

Preguntas para practicar

¿Por qué recomiendan la logística si en validación ganaba el boosting? Ver «Punto 1» arriba: 2019 no ajustó nada, costo y explicabilidad ya favorecían a la logística, y 2019 mostró que la ventaja del boosting no se sostenía.

¿La validación temporal era pesimista u optimista? Las dos cosas, según el modelo: pesimista para la logística (catálogo nuevo), optimista para los árboles (sobreajuste). Ver «Punto 2».

¿Por qué la AP trivial es 0,406 y no 0? Porque es la prevalencia de 2018: un puntaje constante ordena al azar.

¿Por qué no validación cruzada mezclada? Porque pone reclamos del mismo día en entrenamiento y validación; infla el AUC del bosque de 0,753 a 0,882.

¿Por qué cambiaron de bache a boca de tormenta? Porque los baches están repartidos de forma pareja: DBSCAN no encuentra focos, encuentra la ciudad.

¿Por qué ε = 270 m y no el codo? El codo une todo el casco urbano. La mediana marca «más denso que lo típico», que es lo que es un foco.

¿Por qué el silhouette no elige DBSCAN? Porque mide compacidad y separación, no concentración; una partición en zonas compactas lo maximiza aunque no haya focos.

¿Qué pasa si k-medias se ajusta fuera del pipeline? Los centroides usarían las ubicaciones de validación: la estimación sale optimista.

¿Por qué recomiendan una logística y no el boosting? En 2019 tiene mejor AP y el mismo AUC, ajusta unas 20 veces más rápido y se puede explicar.

¿Qué es el cambio de catálogo y por qué importa? El 26/12/2017 Limpieza cambió sus códigos; en 2018, casi la mitad de la validación tiene tipos casi sin casos en 2017.

¿Qué mide la respuesta? El cierre administrativo en el sistema, no la reparación: hay cierres en bloque años después.

Antes de entregar

1. Que los cuatro puedan explicar flujo, evaluar y el esquema 2017 → 2018.
2. Repasar por qué la AP trivial es la prevalencia y por qué el silhouette no elige los focos.
3. Abrir el notebook y comprobar que estas cifras aparecen en las salidas.
4. Entregar por Moodle el notebook ejecutado.